

LAPORAN TUGAS BESAR COMPILER BAHASA PYTHON

IF2124/Teori Bahasa Formal dan Automata



Dipersiapkan oleh:

Agen Parser

1. Nayotama Pradipta - 13520089
2. Angelica Winasta Sinisuka - 13520097
3. Muhammad Rakha Athaya - 13520108

Sekolah Teknik Elektro dan Informatika - Institut Teknologi Bandung

Jl. Ganesha 10, Bandung 40132

Daftar Isi

BAB I	2
Teori Dasar	2
1.1 Finite Automata	2
1.2 Context Free Grammar	5
1.3 Python Syntax	7
BAB II	9
Hasil Finite Automata dan Context Free Grammar	9
2.1 Isi Context Free Grammar	9
2.2 Isi Finite Automata	12
BAB III	13
Implementasi dan Pengujian	13
3.1 Implementasi	13
3.2 Pengujian	15
BAB IV	18
Kesimpulan dan Saran	18
4.1 Kesimpulan	18
4.2 Saran	18
Lampiran	19

BAB I

Teori Dasar

1.1 Finite Automata

Secara sederhana, *finite automata* dapat diartikan sebagai suatu model komputasional abstrak dan sederhana yang memiliki lima elemen atau *tuples*. Elemen dari sebuah *finite automata* meliputi:


1. Q : *Finite set of states*
2. Σ : *Set of Input symbols*
3. q : *Initial state*
4. F : *Set of final states*
5. δ : *Transition function*

Ciri khas dari *finite automata* adalah adanya transition rules yang mentransformasikan dari satu state ke state lain. Representasi FA paling sederhana adalah menggunakan graf ataupun tabular. Di dalam graf, *nodes* menandakan *states* atau keadaan, panah menunjukkan transisi, serta label pada panah menunjukkan input yang menyebabkan transisi. Pada representasi tabular, tabel diisi dengan fungsi δ yang menunjukkan *set of states* dan input symbols.

Transition function (δ) menerima dua argumen, yaitu sebuah *state* dan sebuah input symbol. Sebagai contoh:

$\delta(q,a)$ menunjuk kepada *state* yang dituju ketika FA berada pada state q dan menerima input dalam bentuk a .

FA dibagi menjadi dua bentuk/tipe, yaitu DFA (*Deterministic Finite Automata*) dan NFA (*Non-deterministic Finite Automata*). Pada DFA, automata hanya dapat bergerak ke satu state ketika menerima satu input dan tidak bisa menerima null (ϵ). Pada DFA juga dikenal istilah *dead state*, yaitu state yang sudah tidak mungkin menuju ke final state. Suatu DFA dapat didefinisikan dalam *five-tuple notation*: $A = (Q, \Sigma, \delta, q_0, F)$. Pada DFA, fungsi transisi didefinisikan sebagai $\delta: Q \times \Sigma \rightarrow Q$.




Gambar 1.1.1 Graf/Diagram DFA yang menerima input berupa 0 dan 1 dengan masing-masing berjumlah yang genap

	0	1
* \rightarrow q_0	q_2	q_1
q_1	q_3	q_0
q_2	q_0	q_3
q_3	q_1	q_2

Gambar 1.1.2 Representasi Tabular untuk DFA yang sama pada gambar 1.1.1

Pada NFA, automata dapat pindah menuju lebih dari satu state ketika menerima satu input. Selain itu, terdapat tipe NFA bernama ϵ -NFA yang juga memungkinkan *transition* ke state lain hanya dengan input ϵ atau *empty string*.

Pada NFA, fungsi transisi didefinisikan sebagai $\delta: Q \times (\Sigma \cup \epsilon) \rightarrow 2^Q$.



Gambar 1.1.3 Representasi graf ϵ -NFA yang menerima input berupa bilangan desimal

	ϵ	$+, -$	$.$	$0, 1, \dots, 9$
q_0	$\{q_1\}$	$\{q_1\}$	\emptyset	\emptyset
q_1	\emptyset	\emptyset	$\{q_2\}$	$\{q_1, q_4\}$
q_2	\emptyset	\emptyset	\emptyset	$\{q_3\}$
q_3	$\{q_5\}$	\emptyset	\emptyset	$\{q_3\}$
q_4	\emptyset	\emptyset	$\{q_3\}$	\emptyset
q_5	\emptyset	\emptyset	\emptyset	\emptyset

Gambar 1.1.4 Representasi tabular ϵ -NFA yang sama dengan gambar 1.1.3

Pada fungsi transisi kedua bentuk FA, Q adalah subset dari 2^Q , maka dapat disimpulkan bahwa semua DFA adalah NFA tetapi tidak berlaku sebaliknya. Meskipun demikian, NFA dapat diubah menjadi DFA yang ekuivalen. Jika ditinjau dari fungsinya, NFA lebih digunakan untuk konsep dan teori, sedangkan DFA digunakan pada compiler di bagian lexical analysis.

1.2 Context Free Grammar

Context free grammar merupakan notasi untuk *languages* yang lebih kuat dibandingkan FA (finite automata) atau RE(*regular expression*), tetapi tidak mendefinisikan semua *languages* yang mungkin. Context free grammar sangat baik digunakan untuk struktur yang *nested*, seperti tanda kurung di bahasa pemrograman

Terdapat 3 komponen didalam CFG yaitu:

1. Terminal: Simbol dari huruf language yang didefinisikan.
2. Variables: Variabel disebut juga dengan non terminal, yaitu set simbol yang berhingga dan setiap set melambangkan suatu bahasa.
3. Start Symbol: variabel yang bahasanya sedang didefinisikan

Produksi dari CFG punya bentuk variabel, yaitu string yang terdiri dari variabel dan terminal. Konvensinya adalah sebagai berikut:

- A,B,C, : variabel
- a, b,c, : terminal
-,X,Y,X : terminal atau variabel
-,q,x,y,z : terminal strings

Derivation dilakukan pada string language CFG pada start simbol. Kemudian menggantikan beberapa variabel A ke kanan dari produksinya. *Iterated Derivation* ialah langkah yang melakukan derivation nol kali atau lebih dari nol. *Sentential Forms* merupakan string yang variabel atau/dan terminal *derived* dari start simbol.

Jika G merupakan CFG, maka $L(G)$ yang merupakan language dari G adalah $\{w \mid S \Rightarrow^* w\}$ dengan syarat w harus merupakan string terminal dan S adalah start simbol. Derivation memperbolehkan untuk mengganti variabel dalam string. Terdapat banyak cara saat derivaion dengan derivation string. Kita dapat menggantikan variabel paling kanan atau kiri untuk menghindari perbedaan.

Contoh dari *leftmost derivation* dan *rightmost derivation* ialah *balanced-parentheses grammar* ,sebagai berikut:

$$S \rightarrow SS \mid (S) \mid ()$$

$$S \rightarrow SS \rightarrow (S)S \rightarrow (())S \rightarrow (())()$$


$$\text{sehingga, } S \rightarrow^* (())()$$

Contoh untuk Rightmost Derivation

$$S \rightarrow SS \mid (S) \mid ()$$

$$S \rightarrow SS \rightarrow S() \rightarrow (S)() \rightarrow (())()$$

Parse trees merupakan pohon yang digambarkan oleh simbol dari CFG yang spesifik. Daun (*leaves*) digambarkan dengan terminal atau epsilon. *Interior nodes* digambarkan dengan variabel, dan *root* digambarkan oleh *start symbol*. Contoh dari *parse tree* adalah sebagai berikut:



Gambar 1.2.1 parse tree

Concatenation dari label daun dari urutan kiri ke kanan (*preorder transversal*) disebut dengan *yield* dari parse tree. *Yield* yang dihasilkan dari parse tree di atas adalah $(())()$

Untuk setiap *parse tree*, terdapat *unique leftmost* dan *unique rightmost derivation*. CFG dikatakan ambigu apabila terdapat string dalam *language* yang menghasilkan 2 atau lebih parse trees. Sebagai contoh, ekspresi di prolangu. Operator + dan * dan argumen merupakan identifiers, i.e strings di

$$L((a + b)(a+b+0+1)^*)$$

Ekspresi tersebut didefinisikan oleh grammar

$$G = (\{E, I\}, T, P, E)$$

$T = \{+, *, (,), a, b, 0, 1\}$ dan P adalah set produksi sebagai berikut

1. $E \rightarrow I$
2. $E \rightarrow E + E$
3. $E \rightarrow E * E$
4. $E \rightarrow (E)$
5. $I \rightarrow a$
6. $I \rightarrow b$
7. $I \rightarrow la$

8. $I \rightarrow Ib$
9. $I \rightarrow IO$
10. $I \rightarrow I1$


Sentential form $E + E * E$ mempunyai 2 *derivation*, yaitu

$$E \rightarrow E + E \rightarrow E + E * E$$

dan

$$E \rightarrow E * E \rightarrow E + E * E$$

Yang memberikan kita 2 bentuk *parse trees*, yaitu



Gambar 1.2.2 2 buah parse tree

1.3 Python Syntax

Bahasa pemrograman Python adalah bahasa yang dieksekusi oleh sebuah interpreter. Interpreter tersebut bertugas untuk memarsing sintaks python, dan kemudian merubahnya menjadi sebuah instruksi mesin baris per baris. Terdapat beberapa aturan penulisan sintaks pada bahasa pemrograman Python. Aturan-aturan tersebut harus diikuti agar interpreter bisa memarsing dan menjalankan aplikasi dengan baik. Jika tidak, maka aplikasi tidak akan berjalan dan memproduksi sebuah error. Secara umum, sintaks penulisan python bersifat:

- *Case sensitive*
- Tidak menggunakan titik koma
- Indentasi digunakan sebagai pembentuk struktur
- Tidak ketat terhadap tipe data
- *Human friendly*

Case sensitive, artinya dalam bahasa Python huruf kecil dan besar (kapital) akan dianggap sebagai dua hal yang berbeda. Sebagai contoh, "kota_tua" \neq "Kota_Tua". *Statement* adalah sebuah pernyataan atau instruksi yang akan dieksekusi oleh mesin. Pada umumnya di bahasa pemrograman lain setiap statement akan dibedakan berdasarkan adanya karakter titik koma (;), berbeda dengan Python yang **menggunakan karakter ganti baris** ($\backslash n$). Setiap pergantian baris, interpreter akan menganggap bahwa sebuah statement telah sempurna.

Namun, karakter titik koma tetap dapat digunakan apabila terdapat banyak statement dalam satu baris.

Dalam python, ***indentasi digunakan untuk mendefinisikan struktur blok kode*** program. Kesalahan indentasi bisa berujung pada sebuah error. Indentasi itu sendiri adalah penulisan paragraf yang agak menjorok masuk ke dalam. Dalam penulisan kode, indentasi dapat dibentuk dengan menggunakan spasi beberapa kali atau tab.

Selain itu, bahasa python bersifat ***tidak ketat terhadap tipe data***, di mana kita bisa memberi dan mengubah nilai apapun dari tipe data apapun ke dalam sebuah variabel. Sebagai contoh, variabel *a* yang awal mula diisi dengan nilai integer *100* dapat kita ganti isinya dengan nilai string "kesukaanku".

BAB II

Hasil Finite Automata dan Context Free Grammar

2.1 Isi Context Free Grammar

$S \rightarrow S S$ $S \rightarrow \text{COM IM}$ $S \rightarrow \text{IM COM}$ $S \rightarrow \text{METHOD COM}$ $S \rightarrow \text{COM METHOD}$ $S \rightarrow \text{COM}$ $S \rightarrow \text{IM}$ $S \rightarrow \text{METHOD}$ $S \rightarrow \text{FOR_METHOD}$ $S \rightarrow \text{PRINT_METHOD}$ $S \rightarrow \text{IFELSE}$ $S \rightarrow \text{WHILE_METHOD}$ $S \rightarrow \text{DEF}$ $S \rightarrow \text{WITH}$ $S \rightarrow \text{CLASS}$ $S \rightarrow \text{OBJ}$ $S \rightarrow \text{ASSIGN}$ $S \rightarrow \text{RETURN}$ $S \rightarrow \text{PASS}$ $S \rightarrow \text{RAISE}$ $S \rightarrow \text{BREAK}$ $S \rightarrow \text{CONTINUE}$ $S \rightarrow \text{ARBITRARY_METHOD}$ $\text{COM} \rightarrow \text{COMS NEWLINE}$ $\text{COM} \rightarrow \text{COMS}$ $\text{COMS} \rightarrow \text{'COMMENT'}$ $\text{IM} \rightarrow \text{'FROM' A}$ $\text{IM} \rightarrow \text{B}$ $\text{A} \rightarrow \text{IDENTIFIER B}$ $\text{B} \rightarrow \text{'IMPORT' C}$ $\text{C} \rightarrow \text{IDENTIFIER D}$ $\text{C} \rightarrow \text{IDENTIFIER}$ $\text{D} \rightarrow \text{'AS' E}$ $\text{E} \rightarrow \text{IDENTIFIER IMEND}$ $\text{E} \rightarrow \text{IDENTIFIER}$ $\text{IMEND} \rightarrow \text{NEWLINE}$ $\text{IDENTIFIER} \rightarrow \text{'IDENTIFIER'}$ WITH_METHOD $\text{IDENTIFIER} \rightarrow \text{'IDENTIFIER'}$ $\text{IDENTIFIER} \rightarrow \text{NUMBER}$ $\text{IDENTIFIER} \rightarrow \text{'TRUE'}$	$\text{EXP} \rightarrow \text{EXP B}$ $\text{B} \rightarrow \text{BINARY_OP EXP}$ $\text{B} \rightarrow \text{ARITHMETIC_OP EXP}$ $\text{EXP} \rightarrow \text{LP C}$ $\text{C} \rightarrow \text{EXP RP}$ $\text{COMP_OP} \rightarrow \text{'DOUBLEEQUAL'}$ $\text{COMP_OP} \rightarrow$ $\text{'GREATER_OR_EQUAL_THAN'}$ $\text{COMP_OP} \rightarrow \text{'LESS_OR_EQUAL_THAN'}$ $\text{COMP_OP} \rightarrow \text{'GREATER_THAN'}$ $\text{COMP_OP} \rightarrow \text{'LESS_THAN'}$ $\text{COMP_OP} \rightarrow \text{'NOT_EQUAL'}$ $\text{BINARY_OP} \rightarrow \text{'AND'}$ $\text{BINARY_OP} \rightarrow \text{'OR'}$ $\text{NOT} \rightarrow \text{'NOT'}$ $\text{WHILE_METHOD} \rightarrow \text{WHILE W1}$ $\text{W1} \rightarrow \text{IDENTIFIER W4}$ $\text{W1} \rightarrow \text{EXP W4}$ $\text{W1} \rightarrow \text{LP W2}$ $\text{W2} \rightarrow \text{IDENTIFIER W3}$ $\text{W2} \rightarrow \text{EXP W3}$ $\text{W3} \rightarrow \text{RP W4}$ $\text{W4} \rightarrow \text{COLON NEWLINE}$ $\text{W4} \rightarrow \text{COLON}$ $\text{WHILE} \rightarrow \text{'WHILE'}$ $\text{NEWLINE} \rightarrow \text{'NEWLINE'}$ $\text{DEF} \rightarrow \text{DEFW DEF1}$ $\text{DEF1} \rightarrow \text{IDENTIFIER DEF2}$ $\text{DEF1} \rightarrow \text{IDENTIFIER COLON}$ $\text{DEF2} \rightarrow \text{DEF4}$ $\text{DEF2} \rightarrow \text{LP DEF3}$ $\text{DEF3} \rightarrow \text{DEF4}$ $\text{DEF3} \rightarrow \text{IDENTIFIER DEF4}$ $\text{DEF3} \rightarrow \text{STRING DEF4}$ $\text{DEF3} \rightarrow \text{NUMBER DEF4}$ $\text{DEF3} \rightarrow \text{IDENTIFIER}$ $\text{DEF3} \rightarrow \text{STRING}$ $\text{DEF3} \rightarrow \text{NUMBER}$ $\text{DEF3} \rightarrow \text{DEF3 DEFINBETWEEN}$ $\text{DEFINBETWEEN} \rightarrow \text{COMA DEF3}$ $\text{DEF4} \rightarrow \text{RP COLON}$
--	---

<p> IDENTIFIER → 'FALSE' IDENTIFIER → OBJ WITH_METHOD → 'WITH_METHOD' IDENTIFIER PRINT_METHOD → PRINT M1 M1 → LP M2 M2 → OBJ RP M2 → RP M2 → STRING MS M2 → FLOAT MF M2 → IDENTIFIER MS M2 → NUMBER M2 → EXP RP MS → RP MS → PLUS MPLUSSTRING MS → MULTIPLY MMULTIPLYINTEGER MS → COMA M2 MMULTIPLYINTEGER → NUMBER MS MPLUSSTRING → STRING MS MPLUSSTRING → IDENTIFIER MS MF → RP MF → COMA M2 MF → PLUS MNUMBER MF → MULTIPLY MNUMBER MF → MINUS MNUMBER MF → DIVIDE MNUMBER MF → POWER MNUMBER MI → RP MI → COMA M2 MI → PLUS MNUMBER MI → MULTIPLY M2 MI → MINUS MNUMBER MI → DIVIDE MNUMBER MI → POWER MNUMBER MNUMBER → NUMBER MF MNUMBER → NUMBER MI MNUMBER → FLOAT MF MNUMBER → FLOAT MI NUMBER → 'NUMBER' MULTIPLY → 'MULTIPLY' PRINT → 'PRINT' PLUS → 'PLUS' COMA → 'COMA' FUNC → 'FUNC' STRING → 'STRING' FLOAT → 'FLOAT' FOR_METHOD → FOR F1 F1 → IDENTIFIER F2 F2 → IN F3 F3 → IDENTIFIER COLON </p>	<p> DEFW → 'DEF' WITH → WITHW WITH0 WITH0 → IDENTIFIER WITH1 WITH1 → LP WITH2 WITH2 → IDENTIFIER WITH3 WITH2 → STRING WITH3 WITH2 → NUMBER WITH3 WITH3 → RP WITH4 WITH3 → COMA WITH2 WITH4 → COLON WITH4 → 'AS' WITH5 WITH5 → IDENTIFIER COLON WITHW → 'WITH' CLASS → CLASSW CLASS1 CLASS1 → IDENTIFIER COLON CLASS1 → IDENTIFIER DEF2 CLASSW → 'CLASS' OBJ → 'STRING' OBJ → NUMBER OBJ → 'IDENTIFIER' OBJ → 'FALSE' OBJ → 'NONE' OBJ → 'TRUE' OBJ → OBJ OBJ1 OBJ → STRING OBJ1 OBJ → OBJ OBJ3 OBJ → OBJ OBJ0 OBJ → OBJ OBJ0 OBJ → OBJ OBJIN OBJIN → IN OBJ OBJ0 → ARRAY OBJ0 → ARRAY OBJ1 OBJ0 → ARRAY OBJ3 OBJ1 → 'WITH_METHOD' OBJ2 OBJ2 → OBJ OBJ2 → 'IDENTIFIER' ARRAY OBJ2 → OBJ OBJ3 OBJ3 → LP OBJ4 OBJ3 → LP OBJRP OBJRP → RP OBJ4 → IDENTIFIER OBJ5 OBJ4 → STRING OBJ5 OBJ4 → NUMBER OBJ5 OBJ4 → OBJ OBJ5 OBJ4 → EXP OBJ5 OBJ4 → OBJ5 OBJ5 → ARITHMETIC_OP AOP1 AOP1 → OBJ4 OBJ5 → RP OBJ5 → RP OBJ1 </p>
---	---

F3 → ARBITRARY_METHOD F10 F10 → RP COLON F10 → RP FOR → 'FOR' IN → 'IN' LEN → 'LEN' RANGE → 'RANGE' COLON → 'COLON' IFELSE → IF IF2 IFELSE → IF4 IFELSE → IF7 IFELSE → IF IF97 IF97 → OBJ IF0 IF0 → IN IF1 IF1 → OBJ COLON IF2 → EXP IF3 IF3 → COLON IFNL IF3 → COLON IFNL → NEWLINE IFNEXT IFNEXT → CONTENT IF4 → ELIFTOK IF99 IF99 → ELIF IF5 IF5 → EXP IF6 IF5 → IDENTIFIER IF0 IF6 → COLON IFNL IF6 → COLON IF7 → ELIFTOK IF98 IF98 → ELSE IF8 IF8 → COLON IF9 IF8 → COLON IF9 → NEWLINE IF10 IF9 → IF10 IF10 → CONTENT IF → 'IF' ELSE → 'ELSE' ELIF → 'ELIF' ELIFTOK → 'ELIFTOK' CONTENT → S EXP → OBJ EXP → OBJ A EXP → EXP A A → COMP_OP EXP EXP → NOT EXP EXP → NOT EXP	OBJ2 → OBJ1 ASSIGN → OBJ ASS1 ASS1 → EQUALS OBJ ASS1 → EQUALS NUMBER ASS1 → EQUALS STRING ASS1 → EQUALS ARRAY ASS1 → EQUALS EXP ARRAY → 'LB' ARR1 ARR1 → 'RB' ARR1 → OBJ 'RB' ARR1 → STRING 'RB' ARR1 → NUMBER 'RB' ARR1 → 'IDENTIFIER' ARR2 ARR1 → 'IDENTIFIER' 'RB' ARR2 → FOR_METHOD 'RB' EQUALS → 'EQUALS' ARITHMETIC_OP → 'MINUS' ARITHMETIC_OP → 'PLUS' ARITHMETIC_OP → 'MULTIPLY' ARITHMETIC_OP → 'DIVIDE' ARITHMETIC_OP → 'POWER' ARITHMETIC_OP → 'MOD' ARITHMETIC_OP → 'MINUS' EQUALS ARITHMETIC_OP → 'PLUS' EQUALS ARITHMETIC_OP → 'MULTIPLY' EQUALS ARITHMETIC_OP → 'DIVIDE' EQUALS ARITHMETIC_OP → 'POWER' EQUALS ARITHMETIC_OP → 'MOD' EQUALS RETURN → 'RETURN' OBJ PASS → 'PASS' RAISE → 'RAISE' OBJ BREAK → 'BREAK' CONTINUE → 'CONTINUE' ARBITRARY_METHOD → IDENTIFIER ARM1 ARM1 → LP ARM2 ARM2 → ARBITRARY_METHOD RP ARM2 → ARM1 RP ARM2 → OBJ RP ARM2 → EXP RP LP → 'LP' RP → 'RP' MULTILINE → "TRIPLEQUOTE"
--	--

Gambar 2.2.1 Graf/Diagram DFA yang menerima input berupa variabel sesuai dengan sintaks python

BAB III

Implementasi dan Pengujian

3.1 Implementasi

Garis Besar

Program yang kami buat terdiri atas enam file utama dan beberapa file input untuk pengetesan. Dari enam file utama, lima merupakan file python sedangkan yang satu adalah text file yang berisi context free grammar. Pada dasarnya file yang berisi alur program ada pada main.py. File ini memerlukan import dari file lexer, parser, dan lexer Rules. Program main akan meminta file input dalam bentuk python file ataupun text file. Kemudian program akan membuat objek dengan fungsi lexer, yang menerima rules dari lexerRules dan digunakan untuk proses lexing. Setelah lexing, program akan melakukan parsing dengan bantuan parser.py serta input grammar.txt. Pada saat proses parsing, program akan menghitung jumlah syntax error yang ditemukan hingga keseluruhan input file telah diparse. Jika tidak ada error maka program akan output ke terminal berupa "Accepted", jika ada error maka program akan memunculkan jumlah error serta menampilkan kalimat yang menyebabkan error. Program juga dapat menghitung run time menggunakan module time.

File

1. grammar.txt

File ini berisi context free grammar yang akan digunakan untuk mengevaluasi syntax file input.

2. cfmtocnf.py

File ini digunakan untuk meng*convert* CFG pada grammar.txt menjadi sebuah grammar dalam bentuk Chomsky Normal Form. Di dalam file ini terdapat tiga fungsi, yaitu:

- Read_grammar : Membaca grammar dari sebuah file
- Add_rule : Menambahkan rule ke dalam RULE_DICT yang merupakan global var
- convert_grammar: Fungsi utama pada file ini yaitu untuk mengubah grammar pada grammar.txt yang berbentuk CFG menjadi CNF

3. CYKparser.py

Seperti namanya, file ini berisi parser yang mengimplementasikan algoritma Cocke-Younger-Kasami (CYK). Tujuan dari adanya file `cfgtocnf.py` adalah karena algoritma CYK membutuhkan grammar CNF sebagai masukannya. File ini berisi dua class, yaitu sebuah Node dan Parser itu sendiri. Di dalam class Node terdapat konstruktor `init` untuk mengkonstruksi `symbol`, `anak1`, dan `anak2`, serta terdapat method `repr` untuk merepresentasikan objek sebagai string. Di dalam class Parser terdapat konstruktor `init` untuk mengkonstruksi tabel parsing, production rules, grammar, string input, dan sentence. Di dalam class Parser juga ada method `call` dan `dell`, serta fungsi untuk membaca dari file maupun dari string. Ada fungsi `parse` untuk melakukan parsing pada hasil input file, dan yang terakhir ada fungsi `print tree` untuk menghasilkan output berupa kesalahan syntax jika ada kesalahan.

4. testdfa.py

File ini mendeklarasikan states-states yang dibutuhkan untuk menerima input berbagai simbol pada file eksternal. File ini mengandung fungsi `dfa` yang akan memproses dan memilah kata yang termasuk variabel tiap baris dalam file eksternal.

5. Lexer.py

File ini berfungsi untuk mengubah input menjadi token-token yang akan digunakan pada proses parsing. File ini memiliki satu class bernama `Changing`, dan di dalamnya terdapat konstruktor, fungsi `token`, dan fungsi `tokens`.

6. lexerRules.py

File ini isinya rules yang digunakan pada `lexer.py`. Aturan ini termasuk triple quotes, number and floats, mathematical operators, punctuation, comparison operators, value assignment, whitespace and newline, string, print, identifier, random case, serta python keyword yang harus terdaftar sesuai dengan spek tubes.

7. Main.py

File ini merupakan program utama yang dijalankan untuk mengevaluasi sintaks dan nama-nama variabel dari input file eksternal yang berisi string kode program Python. Jika input diterima akan meng-*output* "Accepted!" atau "Syntax Error!" (beserta jumlah error-nya) bila tidak diterima.

3.2 Pengujian

File inputAcc.py

```
AgenParserTBFO > inputAcc.py > do_something
1  def do_something(x):
2      ''' This is a sample multiline comment
3      '''
4      if x == 0:
5          return 0
6      elif x + 4 == 1:
7          if True:
8              return 3
9          else:
10             return 2
11     elif x == 32:
12         return 4
13     else:
14         return "Doodoo"
```

Gambar 3.2.1 Program inputAcc.py

Hasil pengujian

```
PS C:\Users\Lenovo\Desktop\ITB\IF\Semester
Input file to check : inputAcc.py
Parsing 14 line(s) of code...
Accepted!
Time Execution: 0.21960 second(s)
Terminating parser...
```

Gambar 3.2.2 Output proses inputAcc.py

Penjelasan

File inputAcc tidak memiliki syntax yang bermasalah ataupun tidak sesuai dengan grammar sehingga file diterima oleh program (output dalam bentuk "Accepted!").

File inputReject.py

```
1  def do_something(x):
2      ''' This is a sample multiline comment
3      ...
4      x + 2 = 3
5      if x == 0 + 1
6          return 0
7      elif x + 4 == 1:
8          else:
9              return 2
10     elif x == 32:
11         return 4
12     else:
13         return "Doodoo"
14
```

Hasil pengujian

```
FO/main.py"
Input file to check : inputReject.py
Parsing 14 line(s) of code...
Kalimat tidak termuat dalam bahasa dari grammar yang diberikan!
  IDENTIFIER PLUS NUMBER EQUALS NUMBER
Kalimat tidak termuat dalam bahasa dari grammar yang diberikan!
  IF IDENTIFIER DOUBLEEQUAL NUMBER PLUS NUMBER
Kalimat tidak termuat dalam bahasa dari grammar yang diberikan!
  ELIF IDENTIFIER DOUBLEEQUAL NUMBER COLON
Kalimat tidak termuat dalam bahasa dari grammar yang diberikan!
  ELSE COLON
Syntax Error! 4 error yang ditemukan dalam file.
Time Execution: 0.34701 second(s)
Terminating parser...
```

Penjelasan

File inputReject memiliki beberapa syntax yang bermasalah dan tidak sesuai dengan grammar, sehingga file ditolak oleh program (output dalam bentuk "Syntax Error!"). Error pertama dari baris keempat dimana "x + 2 = 3" berbentuk identifier plus number equals number yang tidak ada dalam bahasa dari grammar (karena "=" untuk assignment). Pada baris kelima, pernyataan if semestinya diakhiri dengan kolon. Pada baris kesepuluh, pernyataan elif didahului pernyataan else yang menjadi pernyataan pertama dalam bloknya. Pada baris kedua belas salah karena tidak terdapat dalam bahasa dari grammar.

File inputTest.py

```
AgenParserTBFO > inputTest.py > ...
1  import blablabla some_random_module as mod
2
3  def iterate(x):
4      for i in item:
5          x += 1
6          print(x)
7
8  123Abc = 5
```

Hasil pengujian

```
Input file to check : inputTest.py
Parsing 8 line(s) of code...
Kalimat tidak termuat dalam bahasa dari grammar yang diberikan!
IDENTIFIER IDENTIFIER AS IDENTIFIER
123Abc = 5 Rejected
Syntax Error! 2 error yang ditemukan dalam file.
Time Execution: 0.15259 second(s)
Terminating parser...
```

Penjelasan

File inputTest memiliki dua kesalahan yaitu pada baris 1 dan baris 8. Pada baris 1, "importblablabla" diidentifikasi sebagai identifier. Hal ini dikarenakan "importblablabla" bukan merupakan python keyword "import". Ketika program membaca baris pertama tersebut, maka language yang terbentuk adalah identifier identifier AS identifier. Hal ini bukan termasuk grammar yang benar. Oleh karena itu, program menganggap baris satu sebagai baris dengan syntax error. Selanjutnya pada baris 8 terdapat variabel bernama 123Abc yang bernilai 5. Sebenarnya baris 8 termasuk dalam grammar yang sesuai, akan tetapi penamaan variabel yang dimulai dengan angka memicu DFA dalam deteksi variabel error. Kesimpulannya terdapat dua jenis syntax error pada file inputTest.py, yaitu grammar error dan variabel error.

BAB IV

Kesimpulan dan Saran

4.1 Kesimpulan

Program python dapat berjalan ataupun tidak berjalan berkat adanya lexer dan parser. Lexer menerima input berupa karakter sedangkan parser menerima input dalam bentuk token dari lexer. Kedua program ini bekerja sama untuk mengecek dan memastikan bahwa kode program yang dibuat oleh programmer mengikuti aturan dari bahasa Python. Kedua program inilah yang mampu menampilkan pesan syntax error jika terjadi kesalahan syntax pada saat program di run. Konsep kerja dari keduanya adalah finite automata, regex dan CFG. Algoritma yang bekerja pada masing-masing parser dapat berbeda akan tetapi kami menggunakan algoritma CYK yang menerima grammar CNF. Kami juga tidak secara langsung membuat grammar dalam bentuk CNF melainkan dalam bentuk CFG dan membuat grammar converter untuk memudahkan pengerjaan. Program kami dapat mengecek input file dan mengirimkan output berupa accepted jika tidak ada syntax error, dan output berupa jumlah error beserta kesalahan syntaxnya jika ada error. Tugas besar ini mengajarkan kami banyak sekali pengetahuan akan cara kerja parser dan lexer serta meningkatkan rasa syukur atas adanya kedua program tersebut. Peran parser dan lexer sangatlah besar dalam dunia pemrograman karena keduanya memudahkan programmer dalam mencari letak dan jenis kesalahan pada program.

4.2 Saran

Pengerjaan tugas besar ini tentu tidak luput dari kesalahan. Salah satu kekeliruan kami ialah tidak membuat DFA dari awal sehingga pengecekan syntax variabel menjadi lebih susah. Riset akan parser dan lexer sebaiknya dilakukan lebih mendalam agar lebih mengetahui cara kerja keduanya secara lebih baik.

Lampiran

Repository Github

<https://github.com/NayotamaPradipta/AgenParserTBFO>

Pembagian Tugas

Nayotama Pradipta - 13520089	Membuat file grammar converter, lexerRules, modifikasi parser, membuat dan mengisi main, testing program, pengerjaan laporan
Angelica Winasta Sinisuka - 13520097	testing program, pengerjaan laporan, pembuatan FA, membantu pengerjaan main
Muhammad Rakha Athaya - 13520108	testing program, membuat file grammar, pengerjaan laporan

Daftar Referensi

1. John E. Hopcroft, Rajeev Motwani, Jeffrey D. Ullman, Introduction to Automata Theory , Languages, and Computation, Third Edition, Addison Wesley, 2014
2. <https://github.com/RobMcH/CYK-Parser>
3. https://docs.python.org/3/reference/lexical_analysis.html
4. <https://gist.github.com/eliben/5797351>
5. <https://www.pythonindo.com/source-code-deterministic-finite-automaton-dfa-menggunakan-python/>